

blog_kernel_launch

Dive into Kernel Launch Overhead and Host Synchronization Over head

我们知道 MegaKernel 的核心 motivation 之一是：通过减少 Kernel 的数量减少 Kernel Launch 的开销以及和 host 侧的同步。然而我们始终有下面几个疑问：

1. Kernel Launch 的开销，如何定义？
2. Kernel Launch 的开销、CPU-GPU 同步的开销，如何测算？
3. Kernel Launch 的开销，在不同的 **model** 上具体有多少？对 serving system 有着怎样的影响？

我们围绕上面几个问题，进行理论探究和实验分析。


定义 Kernel Launch 的开销

Definition, E2E Kernel Latency $\approx$ CPU Launch Overhead + Other Overhead + GPU Execution Time (有效时间) + Synchronization Overhead，我们把 CPU Launch Overhead + Other Overhead 统称为 Kernel Launch Overhead，Synchronization Overhead 归类为 CPU-GPU 同步开销，做一个小小的区分。

大体上，Kernel 从 CPU 发射 到 GPU 实际执行 这个过程中发生了什么，以及 Kernel Launch 的开销包含哪些组成部分，如下图所示：

1. Kernel Latency，内核总延迟。以 CPU 的视角观察，一次 e2e 的完整耗时。从 CPU 线程调用内核启动函数 `cuLaunchKernel` 或 `<<<...>>>` 等 CUDA API，一直到 CPU 线程通过 `cudaDeviceSynchronize()` 确认内核在 GPU 上执行完成经过的全部时间。
2. GPU Execution Time，GPU 执行开销。即有效工作部分，实实在在的 GPU 执行时间，完成 GEMM、Norm 等操作花费的时间 -> 通过优化 kernel 代码来降低这部分开销。
3. CPU Launch Overhead，CPU 启动开销。即 CPU 调用内核启动函数本身产生的延迟。CPU 执行 `<<<...>>>`，CUDA Driver 需要在 CPU 上完成一些准备工作，包括：检查和验证启动参数（Grid/Block 维度、SMEM Size 等）、向 Command Buffer（CPU 侧 pinned buffer 上）中填充命令、准备要传输给 GPU 的参数等。这个过程完全在 CPU 上发生，GPU 甚至还未开始工作。
4. Other Overhead，其他开销，卡在 CPU Launch Overhead 和 GPU 执行时间之间的所有环节。包括：命令在 Command Buffer 中的等待时间、CPU->GPU 的通信延迟（即，GPU frontend 去 CPU pinned memory 的 Command Buffer 取指令的时间）、指令在 GPU 硬件队列中排队的时间，GPU 硬件调度器解析命令的时间、GPU 将计算任务分派到 SMs 上的时间等。大概就是这些部分。

5. Synchronization Overhead, 同步开销/主机开销。主要是指 kernel 运行完之后需要和主机进行同步, 特别是 Serving Framework 需要发起一些 CUDA API 操作比如 `cudaMemcpy` 之类的, 并在 CPU Python Runtime 中更新一些 metadata、做一些决策。




Observation, Kernel Launch 和 GPU Execution 是异步的, 形成异步的 producer/consumer 关系。


CPU 把 kernel 解析成一系列命令写进 Command Buffer (位于 CPU 侧 pinned buffer) 即返回, GPU 异步地去 Command Buffer 取单个 kernel 对应的所有命令在 GPU 侧执行。这样的性质形成经典的 producer/consumer 的关系, producer 即 CPU, consumer 即 GPU。Producer 生产的速率即 Kernel Launch Overhead + CPU-GPU synchronization Overhead; Consumer 消费的速率即 GPU Execution Time。

Producer/Consumer 关系:

1. Producer 生产速率 < Consumer 消费速率, Command Buffer 中 kernel 不足, 使 GPU utilization 不足, 存在大量 bubble。此时, CPU Launch Overhead -> Other Overhead -> GPU Execution Time -> Synchronization Overhead, 这四段是串行的。参考下图 (qwen3.5-72B 在 eager mode 下 decode) 中 `nvjet_sm90_tst_64x8_64x16_4x1_v_bz_TNT` 的 lifeline。



2. Producer 生产速率 > Consumer 消费速率，Command Buffer 充满 kernel，这带来 overlap 的机会，可以掩盖 Kernel Launch Overhead。参考下图（qwen3.5-27B 在 eager mode 下做 prompt=8k 下的 prefill），做一些比较大的 GEMM 操作时，很容易将 GPU 计算资源吃满且运行时间较长，此时就会出现 Command Buffer Full 的现象，Kernel A 在 launch 和 execute 之间甚至可能存在秒级的 latency。此时，大量的 kernel launch overhead 都被实际的 GPU execution 掩盖了。所以，所谓计算量更大的情况下 kernel launch overhead 不明显，本质上是因为 kernel launch 被 overlap 掩盖了，而不是单纯的 kernel launch 时间短。（当然不一定需要 Command Buffer full，只要 kernel 足够长就能带来 overlap 的机会）



测算 Kernel Launch Overhead and Host Synchronization Overhead

上一章节的分析中，我们采用 eager mode，观察到明显的 bubble 情况（尤其是在 decode 中），本章节我们引入 cuda graph，观察 cuda graph 对 bubble 的消除能力，从而思考在有了 cuda graph 的情况，MegaKernel 通过减少 Kernel 的数量减少 Kernel Launch 的开销以及和 host 侧的同步的 motivation 是否站的住脚。

测算指标

首先，我们定义一些我们使用的指标：

- e2e_ms，端到端时间。表示一次 generate() 从 CPU 侧开始到结束的总耗时，包含 GPU 执行、CPU 调度、kernel launch、同步、sampling 等。
- total_kernel_gpu_ms，所有 kernel 执行时长的简单求和： $\text{total_kernel_gpu_ms} = \sum(\text{kernel.end} - \text{kernel.start})$ ，注意它不是 GPU 忙碌时间。如果多个 kernel 在不同 stream 上重叠执行，这个值会重复计入重叠部分，因此可能出现： $\text{total_kernel_gpu_ms} > \text{e2e_ms}$ 。
- launch_overhead_ms，CPU 侧 kernel launch API 调用耗时的累计和。统计的 API 包括：cudaLaunchKernel*、cudaGraphLaunch*、cuLaunchKernel*。测算方式： $\text{launch_overhead_ms} = \sum(\text{launch_api.end} - \text{launch_api.start})$ ，在 command buffer 空闲的情况下大致在 2-10 us 这个量级，但当 command buffer full，迅速膨胀到 ms 级、s 级。以及这个 overhead 只能反映 CPU Launch Overhead，无法反映 Other Overhead + CPU-GPU Synchronization Overhead，因此我们不推荐单纯观察这个指标。

- `launch_overhead_pct`, launch API 累计耗时占 e2e 的比例: $\text{launch_overhead_pct} = \text{launch_overhead_ms} / \text{e2e_ms} * 100\%$, 这个指标只适合粗略估算, 不适合直接解释性能瓶颈。原因是: `compute-bound` 场景里 launch API 可能因为队列反压被撑大而高估影响; `launch-bound` 小模型/decode 场景里 API 本身很短, 但 kernel 之间 GPU 空转很大, 反而低估影响, 因此我们不推荐单纯观察这个指标。

下面一些指标对我们的 **profiling** 有更佳意义:

- `gpu_busy_ms`, GPU 真正处于忙碌状态的时间。测算方式是收集所有 GPU activity 区间: kernel、memcpy、memset 等操作, 然后对这些时间区间取并集, 合并重叠部分, 不会因为多 stream 并发而重复计时, 一定满足 $\text{gpu_busy_ms} \leq \text{e2e_ms}$ 。我们手动测算 GPU bubble ratio, 一方面是因为 GPU utilization 对并发 operation 会重复计数, 即 GPU utilization 可能超过 100%, 而我们主要想看 GPU 因 kernel launch + host sync 导致的空闲情况, 因此我们针对并发 operation 取并集计时, 不过经过 check 我们的 `gpu_bubble_ratio` 和 GPU Utilization 的差别其实很小, 不影响判断和结论; 另一方面, 没用 SM Utilization 是因为 vastai 不暴露 GPU 硬件计数器, 导致无法进行 SM Utilization 的测试。
- `gpu_bubble_ratio`, GPU 空闲比例。也就是 e2e 时间里 GPU 没有 activity 的部分, 指示 GPU 有多少时间没有活干: $\text{gpu_bubble_ratio} = (\text{e2e_ms} - \text{gpu_busy_ms}) / \text{e2e_ms}$ 。反映 launch/host/scheduler/sync 导致的真实 GPU bubble。
- `unhidden_launch_api_ms`, 即无法和实际运行的 GPU kernel overlap 的 CPU Launch Overhead, 这完全被暴露出来, 从意义上更接近实际的 CPU Launch Overhead, 可以用来衡量潜在的可以被 CUDA Graph 或 MegaKernel 解决的 Kernel Launch Overhead。
- `other_host_idle_ms`: GPU 空转但 CPU 不在 launch API 中的时间, 通常包括: cudaMemcpy D2H、sampling、scheduler、attention metadata planning、Python runtime 等, 有 $\text{other_host_idle_ms} = \text{gpu_bubble_ms} - \text{unhidden_launch_api_ms}$ 。

关系说明:

```
gpu_bubble_ms
= e2e_ms - gpu_busy_ms
= GPU idle time
= unhidden_launch_api_ms + other_host_idle_ms
```

实验设置


维度	取值
GPU	单卡 H100 80GB
Framework	SGLang + FlashInfer
Models	Qwen3-0.6B / 1.7B / 8B / 14B / 30B-A3B + Qwen3.5-27B

维度	取值
Modes	eager, cudagraph
Prefill-dominant	BS=1, prompt={16,256,1k,4k,8k}
Decode	BS=1, prompt16, decode={128,512}
Batch Decode	BS={1,4,8,16}, prompt16, decode={128,512}

Kernel Launch Overhead and Host Synchronization Overhead for Decode


我们知道 CUDA Graph 能够降低 Kernel Launch Overhead 和 Host Synchronization Overhead，下面我们通过观察在有了 cuda graph 的情况下，MegaKernel 通过减少 **Kernel** 的数量减少 **Kernel Launch** 的开销以及和 **host** 侧的同步的 motivation 是否站的住脚。

我们在 BS=1、prompt=16 下，在 decode=512 的 eager 和 cudagraph 模式下，测算 GPU bubble ratio 如下图所示：



BS=1、prompt=16、decode=512 的 GPU Bubble Ratio

我们在 BS=1、prompt=16 下，做 decode=128 / decode=512 的测试，测算 eager -> cudagraph e2e speedup，结果如下图：



BS=1、prompt=16 下 Decode 的 Eager 到 Cudagraph E2E Speedup

我们对 BS = 1、decode = 512 的测试，进行详细数据的展开如下：

Model	bubble eager - > cg	e2e speedup	TPOT eager - > cg	launch count eager -> cg	bubble ms eager - > cg	unhidden launch ms eager -> cg	other host idle ms eager - > cg
Qwen3-0.6B	84.7% - > 14.0%	5.64x	8.69 - > 1.54	374.9 -> 17.0	7.36 -> 0.22	1.164 -> 0.077	6.20 -> 0.14
Qwen3-1.7B	76.3% - > 8.6%	3.81x	8.73 - > 2.29	374.9 -> 17.0	6.66 -> 0.20	1.132 -> 0.036	5.53 -> 0.16
Qwen3-8B	45.3% - > 2.4%	1.77x	11.40 - > 6.45	513.1 -> 17.0	5.17 -> 0.16	0.929 -> 0.014	4.24 -> 0.14
Qwen3-14B	28.9% - > 2.0%	1.37x	15.03 - > 10.99	568.2 -> 17.0	4.34 -> 0.22	0.677 -> 0.014	3.66 -> 0.21
Qwen3-30B-A3B	88.1% - > 7.8%	7.73x	35.62 - > 4.61	822.5 -> 17.0	31.37 -> 0.36	3.050 -> 0.066	28.32 - > 0.29
Qwen3.5-27B	54.8% - > 1.6%	2.21x	43.33 - > 19.63	975.5 -> 18.0	23.73 -> 0.32	2.244 -> 0.014	21.49 - > 0.31

从上面两幅图，以及详细数据的表格可以看出，我们进行分析：

1. 在 eager decode 中, `other_host_idle_ms` 通常远大于 `unhidden_launch_api_ms`。这说明系统瓶颈不是裸 kernel launch API 时间本身, 而是 launch API 之间的 scheduler / sampling / sync / framework 逻辑让 GPU 等待。
2. 观察 `eager -> cudagraph e2e speedup`, 普遍是非常显著的, 小模型和 MoE decode 最 launch/host-bound, 因此 speedup 最大; 更大的 dense model 下使用 CUDA Graph 的收益会降低, 但依然足够显著。
3. 观察 `launch count eager -> cg` 列, 在 decode 中, CUDA Graph 已经能够显著压缩 kernel launch 的次数; 随着 kernel launch 次数的大幅降低, `unhidden launch ms eager -> cg` 降低到 0.0x ms 的量级, 以 qwen3-8B 为例, 这部分 Kernel Launch Overhead 仅占 TPOT 的 0.2%; 类似地, `other host idle ms eager -> cg` 也大幅降低, 以 qwen3-8B 为例, 这部分 Host Synchronziation Overhead 占 TPOT 的 2%。
4. 观察 `bubble eager -> cg`, CUDA Graph 已经可以将中等模型及大模型的 GPU bubble 压低至 2% 的级别 (几乎完全来自于 Host Synchronization Overhead)。


结合 MegaKernel 进行思考:

- MegaKernel 当然可以节省 Kernel Launch Overhead / CPU Launch Overhead, 但是 CUDA Graph 已经做的足够好。一方面, SGLang 本身就让 Kernel Launch 很好地被 kernel 的执行所掩盖; 另一方面, 使用 CUDA Graph 之后, 单次 decode 所启动的 kernel 数量已经足够少了, 未能掩盖的 Kernel Launch 以及 host 同步开销也已经足够小了。此时, 为了 2% 级别的 host 同步开销, 进而将 CPU 侧控制逻辑放弃, 完全进入 GPU Runtime 调度, 反而可能因为引入更复杂的 GPU 调度/同步逻辑, 导致 Serving System 的性能下降。得不偿失。


Claim, 在 CUDA Graph 适用的 workload (如 decode) 上, CUDA Graph 已经可以极大降低 Kernel Launch Overhead 和 Host Overhead, MegaKernel 通过减少 Kernel 的数量来减少 Kernel Launch Overhead + Host Overhead 的收益上限不高。

然后, 我们在长上下文下进行 decode:

下面的统计使用 `bs1_p8k_d512`, 即 BS=1、prompt=8k 后继续 decode512, 我们统计 decode 段数据。



8k 长上下文 Decode512 的 GPU Bubble Ratio



短上下文与长上下文 Decode512 的 Eager 到 Cudagraph Speedup

Model	bubble eager - > cg	e2e speedup	TPOT eager -> cg	launch count/step eager -> cg	bubble ms/step eager -> cg	unhidden launch ms/step eager -> cg	other host idle ms/step eager -> cg
Qwen3-0.6B	81.1% - > 10.5%	4.73x	9.08 - > 1.92	381.0 -> 17.0	7.37 -> 0.20	1.132 -> 0.048	6.24 -> 0.15
Qwen3-1.7B	71.9% - > 6.7%	3.33x	8.93 - > 2.68	381.0 -> 17.0	6.42 -> 0.18	1.062 -> 0.027	5.36 -> 0.15


Model	bubble eager - > cg	e2e speedup	TPOT eager -> cg	launch count/step eager -> cg	bubble ms/step eager -> cg	unhidden launch ms/step eager -> cg	other host idle ms/step eager -> cg
Qwen3-8B	41.0% - > 2.5%	1.65x	12.38 -> 7.49	521.0 -> 17.0	5.07 -> 0.19	0.927 -> 0.021	4.14 -> 0.17
Qwen3-14B	10.6% - > 2.7%	1.09x	13.63 -> 12.48	577.0 -> 17.0	1.45 -> 0.34	0.242 -> 0.125	1.21 -> 0.21
Qwen3-30B-A3B	86.8% - > 6.4%	7.25x	39.00 -> 5.38	833.0 -> 17.0	33.86 -> 0.35	3.269 -> 0.064	30.60 -> 0.28
Qwen3.5-27B	42.5% - > 1.3%	1.76x	36.08 -> 20.55	979.0 -> 18.0	15.34 -> 0.27	1.541 -> 0.013	13.80 -> 0.26

结果显示，长上下文 KV read 会摊薄一部分 launch/host bubble，但不会消除 decode 中的 host overhead。对较大的 dense model，prompt 从 16 增加到 8k 后，decode 更接近 GPU/KV-read-bound：例如 Qwen3-14B 的 speedup 从 1.37x 降到 1.09x，说明 CUDA Graph 的增量空间已经降低了不少。但小模型和 MoE 仍然明显 launch/host-bound：Qwen3-0.6B 仍有 4.73x speedup，Qwen3-30B-A3B 仍有 7.25x speedup。


大致的 claim 依旧是：在 CUDA Graph 适用的 workload（如 decode）上，即使 decode 的上下文较长，CUDA Graph 依然可以极大降低 Kernel Launch Overhead 和 Host Overhead，MegaKernel 通过减少 Kernel 的数量来减少 Kernel Launch Overhead + Host Overhead 的收益上限不高。

Kernel Launch Overhead and Host Synchronization Overhead for Prefill

对 Qwen3 系列来说，SGLang 的 prefill 默认走 piecewise CUDA Graph，而 Qwen3.5-27B fall back 没有做 piecewise CUDA Graph。



BS=1 Prefill 的 GPU Bubble Ratio



BS=1 Prefill 的 E2E Latency

以 BS=1, prompt=8k, piecewise CUDA Graph Prefill 为例:

Model	e2e ms	launch count	cudaGraphLaunch	bubble ms	bubble%	unhidden launch ms	othe hos idle m
Qwen3-0.6B	51.11	168	29	7.47	14.6%	0.21	7.2
Qwen3-1.7B	82.69	168	29	8.58	10.4%	0.21	8.3
Qwen3-8B	286.74	208	37	6.89	2.4%	0.14	6.7
Qwen3-14B	483.14	228	41	6.69	1.4%	0.15	6.5
Qwen3-30B-A3B	221.47	220	49	8.09	3.7%	0.18	7.9
Qwen3.5-27B	733.65	1,683	0	11.48	1.6%	0.98	10.4

Claim，decode 中 CUDA Graph 已经把 kernel launch 和 host overhead 压到很低，因此 MegaKernel 继续减少 kernel 数量的收益上限有限；prefill 则呈现明显的 prompt-dependent 行为。短 prompt 下，实际 GPU work 太少，prefill 中会形成很高的 GPU bubble；但随着 prompt 增长，GEMM/attention 计算变长，这部分固定开销被明显摊薄：Qwen3-8B/14B/Qwen3.5-27B 的 bubble ratio 已经降到 1%-3% 量级。因此 MegaKernel 的这一 motivation 主要在中小 prompt 下成立。


BS=1 summary

Claim1，在 CUDA Graph 适用的 workload（如 decode）上，CUDA Graph 已经可以极大降低 Kernel Launch Overhead 和 Host Overhead，MegaKernel 通过减少 Kernel 的数量来减少 Kernel Launch Overhead + Host Overhead 的收益上限不高。为了 2% 级别的 host 同步开销，进而将 CPU 侧控制逻辑放弃，完全进入 GPU Runtime 调度，反而可能因为引入更复杂的 GPU 调度/同步逻辑，导致 Serving System 的性能下降。得不偿失。


Claim2，prefill 则呈现明显的 prompt-dependent 行为。短 prompt 下，实际 GPU work 太少，prefill 中会形成很高的 GPU bubble；但随着 prompt 增长，GEMM/attention 计算变长，这部分固定开销被明显摊薄：Qwen3-8B/14B/Qwen3.5-27B 的 bubble ratio 已经降到 1%-3% 量级。因此 MegaKernel 通过减少 Kernel 的数量来减少 Kernel Launch Overhead + Host Overhead 的 motivation 主要在中小 prompt 下成立。

联想到之前做的 MPK/vLLM/SGLang 的 TTFT 和 TPOT 性能试验，当时没能解释的 2. 点，和我们今天观察到的其实是相符的：

- 针对 prefill, `prompt_len=16` 的时候, MPK 确实小有优势, 这部分优势很可能就来自于 MegaKernel 对 GPU Bubble 的消解; 但可惜 MegaKernel 的 `mbt=16` 设计使得架构优势在 prefill 上迅速衰减, 甚至在 `prompt_len=32` 的时候就开始比不过 vLLM/SGLang 了。
- 针对 decode, 在我们的实测中, MPK 干不过 vLLM/SGLang CUDA Graph, 这同样和我们观察到的 "CUDA Graph 已经能有效地降低 Kernel Launch 和 Host Overhead" 这一现象是相符的,



MPK/vLLM/SGLang 的 TTFT 性能




MPK/vLLM/SGLang 的 TPOT 性能

Claim3, 按照上面对 GPU bubble 的观察, 单卡 H100 serve 实验模型在 `prompt=1k` 下依然保持 10% 的 bubble, 在 `prompt=256` 下更是普遍有 25% 以上的 bubble。如果能利用 MegaKernel 架构消除这部分 bubble, 同时将 MPK 对 prefill 的支持做好, 同时像 ETC 那样支持动态的 `input_shape`, 看起来 MegaKernel 是可以做好的 prefill 的。

Batch sweep test

下图 给出 decode128 / decode512 的 batch sweep speedup。

Decode batch sweep: eager -> cudagraph e2e speedup



Decode Batch Sweep 的 Eager 到 Cudagraph Speedup

选取 BS=8、prompt=16, decode=512，每次decode 的详细指标表格如下：

Model	bubble eager - > cg	e2e speedup	TPOT eager -> cg	launch count/step eager -> cg	bubble ms/step eager -> cg	unhidden launch ms/step eager -> cg	other host idle ms/step eager -> cg
Qwen3-0.6B	85.4% - > 12.9%	6.00x	10.15 -> 1.69	402.9 -> 17.0	8.67 -> 0.22	1.404 -> 0.060	7.27 -> 0.16
Qwen3-1.7B	76.0% - > 8.8%	3.79x	9.39 - > 2.48	402.9 -> 17.0	7.13 -> 0.22	1.245 -> 0.040	5.88 -> 0.18
Qwen3-8B	44.8% - > 3.4%	1.75x	11.98 -> 6.84	549.1 -> 17.0	5.37 -> 0.23	1.003 -> 0.020	4.37 -> 0.21
Qwen3-14B	15.8% - > 2.4%	1.16x	13.30 -> 11.42	608.3 -> 17.0	2.10 -> 0.27	0.354 -> 0.016	1.75 -> 0.25
Qwen3-30B-A3B	87.9% - > 8.5%	7.57x	39.06 -> 5.16	870.5 -> 17.0	34.32 -> 0.44	3.366 -> 0.080	30.95 -> 0.36
Qwen3.5-27B	55.5% - > 0.5%	2.28x	47.79 -> 20.95	1135.5 -> 18.0	26.53 -> 0.10	2.779 -> 0.004	23.75 -> 0.09

BS=8 的观察和 BS=1 decode=512 基本一致，对于 decode 而言，batch 变大不会消除 cudagraph 的价值，decode 终究是 memory-bound/launch bound 的过程。

Conclusion

在考虑和 CUDA Graph 对比的情况下，MegaKernel “通过减少 kernel 数量降低 launch/host overhead” 这个 motivation 较弱。特别是在较大的 dense model 上，通过 cuda graph 优化后暴露的 GPU bubble 已经很少了，此时为了 2% 级别的 host 同步开销，进而将 CPU 侧控制逻辑放弃，完全进入 GPU Runtime 调度，反而可能因为引入更复杂的 GPU 调度/同步逻辑，导致 Serving System 的性能下降，得不偿失。

不过，在小模型（实际应用价值有限）、大模型短 prompt（稍微真实一些的场景）、MOE（真实）下，即使使用 CUDA Graph，我们往往依然观察到 10% 级别的 GPU bubble，如果通过 MegaKernel 架构能充分利用这部分 bubble，同时保证 GPU 调度/同步逻辑不反过来拖累 GPU kernel 的运行，MegaKernel 的这个 通过减少 kernel 数量降低 launch/host overhead 就依然是有意义的。